
Sistema RAG: Masculinidad, Alienación y Violencia en el Cine Contemporáneo

Parcial 2 — Proyecto de Retrieval-Augmented Generation
HE2: Inteligencia Artificial Aplicada a la Economía
Universidad de los Andes · 2026-1

Integrantes
Santiago Castillo González Laura Parra

26 Mayo de 2026

Repositorio GitHub: github.com/scastillo/Rag-Cine

0. Índice

1. Introducción	3
1.1. El problema	3
1.2. ¿Por qué un LLM genérico no es suficiente?	3
1.3. ¿Por qué RAG y no fine-tuning?	3
1.4. Usuarios objetivo	4
1.5. Conexión con principios económicos	4
2. Dataset y Documentos	4
2.1. Corpus seleccionado	4
2.2. Criterios de selección	5
2.3. Disponibilidad	6
3. Arquitectura del Sistema	6
3.1. Diagrama del pipeline	6
3.2. Modelos seleccionados	8
3.3. Base de datos vectorial: FAISS	8
3.4. Diseño del prompt	9
4. Procesamiento de Documentos	9
4.1. Extracción de texto	9
4.2. Estrategia de chunking	9
4.2.1. Trade-off del tamaño de chunk	10
4.3. Estadísticas del corpus y distribución de chunks	10
5. Embeddings y Base de Datos Vectorial	10
5.1. Modelo de embeddings	10
5.2. Verificación técnica	11
5.3. Scores de similitud	11
6. Recuperación y Generación	12
6.1. Pipeline de recuperación	12
6.2. Justificación del valor de K	13
6.3. El re-ranker	13
6.4. Modelo generador: Mistral-7B-Instruct-v0.3	13
7. Resultados	13
7.1. Preguntas de evaluación	13
7.1.1. Pregunta 1: Alienación masculina	13
7.1.2. Pregunta 2: Violencia e identidad	14
7.1.3. Pregunta 3: Justificación moral de la violencia	14
7.1.4. Pregunta 4: Diferencias entre Taxi Driver y No Country for Old Men	14
7.1.5. Pregunta 5: Nihilismo	14
7.2. Tabla resumen de calidad	15
7.3. Caso de fallo y análisis	15
8. Limitaciones y Conclusiones	15
8.1. Limitaciones identificadas	15

8.2. Propuestas de mejora	16
8.3. Conclusiones	16
Bibliografía	16

1. Introducción

1.1. El problema

El análisis cinematográfico académico exige integrar perspectivas de múltiples disciplinas: teoría del cine, estudios de género, filosofía, psicología social y crítica cultural. Un investigador o estudiante que quiera responder preguntas como “¿*Cómo se relaciona la violencia con la crisis de identidad masculina en el cine de los 70s y 90s?*” necesita sintetizar información dispersa en decenas de papers y ensayos críticos. Este proceso es costoso en tiempo y propenso a sesgos de selección.

El presente proyecto construye un sistema de **Retrieval-Augmented Generation (RAG)** aplicado a un corpus de 12 documentos académicos y críticos sobre cuatro filmes canónicos: *Taxi Driver* (Scorsese, 1976), *Raging Bull* (Scorsese, 1980), *Fight Club* (Fincher, 1999) y *No Country for Old Men* (Coen, 2007). El sistema permite formular preguntas analíticas complejas y recibir respuestas fundamentadas en el corpus, con trazabilidad de fuentes.

1.2. ¿Por qué un LLM genérico no es suficiente?

Un modelo de lenguaje de propósito general como GPT-4 o Mistral-7B presenta tres limitaciones críticas para este dominio:

1. **Falta de contexto específico.** El análisis cinematográfico académico requiere citas, argumentos y marcos teóricos de la literatura especializada. Un LLM sin acceso al corpus responde con generalidades que carecen de sustento bibliográfico.
2. **Riesgo de alucinación.** Los LLMs tienden a inventar citas bibliográficas, atribuir argumentos incorrectamente o mezclar teorías de autores distintos. En un contexto académico esto invalida los resultados.
3. **Información no actualizada.** Publicaciones recientes sobre masculinidad, nihilismo y violencia en el cine no están representadas en los datos de entrenamiento de modelos con fecha de corte anterior a su publicación.

1.3. ¿Por qué RAG y no fine-tuning?

La Tabla 1 compara las dos alternativas principales para especializar un LLM en un dominio.

Cuadro 1: Comparación entre RAG y fine-tuning para este proyecto.

Criterio	Fine-tuning	RAG
Costo computacional	Alto (GPU + horas de entrenamiento)	Bajo (solo inferencia)
Actualización del corpus	Requiere re-entrenar el modelo	Solo re-indexar documentos
Trazabilidad de fuentes	No	Sí (citas automáticas con [n])
Riesgo de overfitting	Alto con corpus pequeño (12 docs)	No aplica
Corpus pequeño	Insuficiente para fine-tuning	Suficiente para RAG
Transparencia	Baja	Alta

Con solo 12 documentos, el fine-tuning produciría overfitting severo y el modelo memorizaría el corpus en lugar de generalizarlo. RAG es la elección técnicamente correcta: permite que el modelo use sus capacidades generales de lenguaje mientras fundamenta cada respuesta en el corpus específico.

1.4. Usuarios objetivo

El sistema está diseñado para tres perfiles de usuario:

- Investigadores de cine y cultura que necesitan síntesis bibliográfica rápida sobre temas transversales.
- Estudiantes de humanidades que analizan conexiones teóricas entre obras cinematográficas.
- Críticos que buscan marcos argumentativos respaldados por literatura académica.

1.5. Conexión con principios económicos

Desde una perspectiva de economía de la información, el RAG reduce el *costo de búsqueda y síntesis* de literatura especializada. El sistema actúa como un intermediario que elimina la fricción entre el corpus documental y el usuario final, democratizando el acceso al análisis cinematográfico académico. El valor generado es análogo al de un motor de búsqueda semántico especializado, con la adición de síntesis generativa.

2. Dataset y Documentos

2.1. Corpus seleccionado

El corpus consta de 12 documentos organizados en dos categorías: 8 papers académicos en formato PDF y 4 ensayos críticos en texto plano. La Tabla 2 describe cada documento.

Cuadro 2: Corpus documental del sistema RAG.

#	Archivo	Referencia	Relevancia temática
1	a1.pdf	Arif, S.N. <i>The Fragile World of Cormac McCarthy's No Country for Old Men</i>	Fragilidad, violencia e incomunicación en un mundo moralmente degradado
2	a2.pdf	Potts, H. <i>No Country for Old Men as Existential Confession</i>	Lectura existencialista de Sheriff Bell como figura de culpa y crisis moral
3	a3.pdf	Vidyalakshmi, A.C. <i>Quest for Identity, Desire and Dreams: Resistance to Consumerist Ideology in Fight Club</i>	Crítica al consumismo y análisis psicoanalítico de identidad y alienación
4	a4.pdf	Petković, R. y Jurleta, G. <i>Martin Scorsese's Character Driven Films: Taxi Driver and Raging Bull</i>	Masculinidad, violencia y redención en protagonistas alienados
5	a5.pdf	Bronfen, E. <i>Noir Hysteria: Figures of Masculinity in Crisis in Contemporary Hollywood Cinema</i>	Crisis de masculinidad y pérdida de autoridad masculina
6	a6.pdf	Montero, N. "You Are Not the Contents of Your Wallet": <i>Alienation and Capitalism in Fight Club</i>	Alienación y crítica al capitalismo mediante estructura narrativa
7	a7.pdf	García, J. <i>The Alienated City in 21st Century Cinema: A Socio-Critical Analysis</i>	Representación de ciudades alienadas, marginalidad y crisis urbana
8	a8.pdf	Almeida, R. <i>Impotence, Resentment, Incredulity: Nihilism in Cinema and Education</i>	Análisis del nihilismo contemporáneo y crisis de valores en el cine
9	a9.txt	Ebert, R. <i>Taxi Driver</i> (ensayo crítico)	Alienación, soledad y violencia en Travis Bickle como figura masculina aislada
10	a10.txt	Ebert, R. <i>Fight Club</i> (ensayo crítico)	Masculinidad tóxica y rechazo del consumismo
11	a11.txt	Ebert, R. <i>Raging Bull</i> (ensayo crítico)	Celos, inseguridad masculina y autodestrucción en Jake LaMotta
12	a12.txt	Ebert, R. <i>No Country for Old Men</i> (ensayo crítico)	Violencia, fatalismo y mal absoluto en el universo de McCarthy

2.2. Criterios de selección

Los documentos fueron seleccionados bajo cuatro criterios:

- **Cobertura fílmica:** cada una de las cuatro películas tiene al menos dos documentos dedicados (uno académico, uno crítico).
- **Diversidad teórica:** el corpus cubre teoría del cine, estudios de masculinidad, filosofía nihilista, psicoanálisis y crítica socioeconómica.
- **Calidad académica:** los PDFs son publicaciones revisadas por pares; los TXTs son ensayos de Roger Ebert, crítico de referencia del cine contemporáneo.
- **Complementariedad:** los papers proveen el marco teórico; los ensayos críticos proveen el análisis aplicado a cada obra concreta.

2.3. Disponibilidad

Todo el corpus está disponible públicamente en el repositorio GitHub del proyecto:

<https://github.com/scastillo/Rag-Cine>

3. Arquitectura del Sistema

3.1. Diagrama del pipeline

La Figura 1 ilustra el flujo completo del sistema RAG implementado.




Figura 1: Pipeline completo del sistema RAG. El flujo va de los documentos fuente hasta la respuesta generada con citas.

El pipeline opera en dos fases. La **fase de indexación** (offline) procesa los documentos, los divide en chunks, genera embeddings y construye el índice vectorial. La **fase de consulta** (online) convierte la pregunta del usuario en un embedding, recupera los chunks más similares, los re-ordena con el reranker y los pasa al LLM para generar la respuesta.

3.2. Modelos seleccionados

La Tabla 3 resume los tres modelos del pipeline.

Cuadro 3: Modelos utilizados en el sistema RAG.

Rol	Modelo	Características clave
Encoder (embeddings)	paraphrase-multilingual-MiniLM-L12-v2	384 dims · 512 tokens máx · 33M params · 50+ idiomas
Re-ranker	mxbai-rerank-base-v1 (mixedbread.ai)	Cross-encoder · re-ordena por relevancia semántica
Decoder (generador)	Mistral-7B-Instruct-v0.3	7B params · cuantización 4-bit NF4 · formato [INST]

3.3. Base de datos vectorial: FAISS

FAISS (*Facebook AI Similarity Search*) almacena los vectores de todos los chunks y permite recuperar los más similares a una consulta en milisegundos. Se eligió FAISS sobre alternativas como Chroma o Pinecone por tres razones:

- No requiere servidor externo: opera completamente en local dentro de Google Colab.
- Está optimizado para búsqueda exacta en corpus pequeños (menos de 100 000 vectores).
- Ofrece persistencia simple mediante `save_local()` y `load_local()`.

La búsqueda por similitud calcula la distancia entre el vector de la consulta y cada vector del índice. Formalmente, la similitud coseno entre dos vectores **a** y **b** es:

$$\text{sim}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \cdot \|\mathbf{b}\|}$$

Dos textos semánticamente similares producen vectores que apuntan en la misma dirección (ángulo $\approx 0^\circ$, $\cos \theta \approx 1$). Textos sin relación producen vectores perpendiculares ($\cos \theta \approx 0$).

3.4. Diseño del prompt

El prompt sigue el formato nativo de Mistral-Instruct (`[INST] ... [/INST]`) y tiene tres componentes:

1. **System instruction:** define el rol del modelo como analista de cine académico e impone la restricción de responder *exclusivamente* con el contexto proporcionado.
2. **Contexto numerado:** los fragmentos recuperados, numerados [1], [2]..., con su nombre de fuente, para habilitar las citas.
3. **Pregunta del usuario:** con instrucción explícita de citar las fuentes mediante su número.

La restricción “responde EXCLUSIVAMENTE con el contexto” es el mecanismo principal de control de alucinaciones. Si el corpus no contiene información relevante para la pregunta, el modelo debe indicarlo explícitamente en lugar de inventar una respuesta.

4. Procesamiento de Documentos

4.1. Extracción de texto

Los PDFs se procesan con **PyMuPDF** (`fitz`), que extrae el texto página a página y aplica limpieza básica (eliminación de saltos de línea múltiples y espacios redundantes). Los archivos TXT se leen directamente con codificación UTF-8. Ambos tipos de documento se unifican en una estructura común con campos `source`, `tipo_doc` y `text`.

4.2. Estrategia de chunking

Se utiliza `RecursiveCharacterTextSplitter` de LangChain con los siguientes parámetros:

Cuadro 4: Parámetros de chunking y justificación.

Parámetro	Valor	Justificación
<code>chunk_size</code>	800 caracteres	≈150–200 tokens, muy por debajo del límite de 512 del encoder. Suficiente para un argumento teórico completo (2–3 oraciones).
<code>chunk_overlap</code>	150 caracteres	Evita que ideas cortadas entre chunks sean inaccesibles. Si una oración empieza al final del chunk n , también aparece al inicio del chunk $n + 1$.
<code>separators</code>	<code>[\n\n, \n, ‘. ’, ‘ ’, ‘’]</code>	Corta preferentemente en párrafos, luego oraciones, luego palabras. Preserva coherencia semántica.

4.2.1. Trade-off del tamaño de chunk

Cuadro 5: Trade-off según tamaño de chunk.

Tamaño	Ventaja	Desventaja
Muy pequeño (<200 chars)	Alta precisión de retrieval	Pierde contexto; una frase aislada carece de significado
Muy grande (>1500 chars)	Contexto completo preservado	Excede el límite del encoder; embedding menos preciso
800 chars (elegido)	Balance contexto/precisión	Óptimo para papers académicos del dominio

4.3. Estadísticas del corpus y distribución de chunks

La Figura 2 muestra la distribución de tamaños de chunks y la cantidad de fragmentos por documento.




Figura 2: Izquierda: distribución de longitudes de chunks (en caracteres). Derecha: número de chunks generados por documento. La línea roja indica la media.

El histograma confirma que la estrategia de chunking opera correctamente: la mayoría de los fragmentos se concentra cerca del `chunk_size` definido. Los chunks más cortos que aparecen en la cola izquierda corresponden a los últimos fragmentos de cada documento, donde el texto restante no alcanza el tamaño completo. La distribución por documento refleja la extensión relativa de cada fuente: los papers académicos más largos generan más chunks que los ensayos críticos.

5. Embeddings y Base de Datos Vectorial

5.1. Modelo de embeddings

Se utiliza **paraphrase-multilingual-MiniLM-L12-v2** de Sentence Transformers. Es un modelo de tipo *encoder*: a diferencia de los decoders que generan texto, este modelo

convierte texto en vectores de representación densa. Los encoders son ideales para embeddings porque su función objetivo durante el entrenamiento es maximizar la similitud entre paráfrasis y minimizarla entre textos no relacionados.

Las características técnicas relevantes son:

- **Dimensionalidad:** 384 dimensiones por vector.
- **Límite de tokens:** 512 tokens por fragmento de entrada.
- **Cobertura lingüística:** más de 50 idiomas, incluyendo español e inglés.
- **Parámetros:** 33 millones — eficiente en la GPU T4 de Google Colab.

La elección de un modelo multilingüe es crítica para este corpus: los 8 PDFs están en inglés y los 4 ensayos de Ebert también, pero las queries del sistema se formulan en español. Un encoder monolingüe generaría embeddings incompatibles entre el corpus y las consultas, degradando la calidad del retrieval.

5.2. Verificación técnica

Se verificó que todos los chunks respetan el límite del encoder:

Output de verificación

```
Dimensionalidad del embedding: 384 dimensiones
Modelo: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2
Límite de tokens del encoder: 512 tokens
Longitud máxima de nuestros chunks: ~800 chars ≈ 200 tokens
→ Todos los chunks están dentro del límite del encoder
```

5.3. Scores de similitud

La Figura 3 muestra los scores de similitud para dos consultas representativas. Los chunks en verde superan el umbral de 0.6 y son considerados altamente relevantes; los rojos tienen relevancia marginal y son filtrados por el re-ranker antes de llegar al LLM.




Figura 3: Scores de similitud para las consultas de alienación masculina (izquierda) y nihilismo en Fight Club (derecha). Verde: score $> 0,6$. Rojo: score $\leq 0,6$. La línea naranja indica el umbral sugerido.

Para ambas consultas, ningún chunk supera el umbral de 0.6. Esto no implica que el retrieval falle: los scores son una conversión aproximada de la distancia L2 de FAISS mediante la fórmula $\text{sim} \approx 1/(1 + d_{L2})$, que comprime los valores en rangos relativamente bajos. Lo que importa es la *ordenación relativa*: los chunks con mayor score son sistemáticamente más relevantes que los de menor score, y el re-ranker refina aún más esta selección. Los resultados de las 5 preguntas de evaluación confirman que el retrieval recuperó fragmentos pertinentes en todos los casos.

6. Recuperación y Generación

6.1. Pipeline de recuperación

Dado un query del usuario, el sistema ejecuta los siguientes pasos:

1. El query se convierte en un embedding de 384 dimensiones usando el mismo encoder del corpus.
2. FAISS busca los $K = 10$ chunks más cercanos en el índice vectorial.
3. El re-ranker `mxbai-rerank-base-v1` evalúa cada par (query, chunk) de forma conjunta y re-ordena los 10 candidatos por relevancia real, seleccionando el top-5.
4. Los 5 chunks seleccionados se ensamblan en el prompt junto con la pregunta.
5. Mistral-7B genera la respuesta.

6.2. Justificación del valor de K

Cuadro 6: Trade-off del valor de K .

Valor de K	Ventaja	Desventaja
$K = 3$	Prompt corto, inferencia rápida	Puede perderse el chunk relevante
$K = 10 \rightarrow \text{top-5}$	El re-ranker filtra los mejores 5 de 10	Más costoso en tiempo de re-ranking
$K = 20$	Mayor recall, menos riesgo de perder info	Contexto demasiado largo; el LLM “se distrae”

Con $K = 10 \rightarrow \text{rerank} \rightarrow \text{top-5}$, el sistema maximiza el recall en la etapa de recuperación y la precisión en la etapa de selección. Si K fuera muy grande, el prompt superaría la ventana de contexto efectiva del LLM y la calidad de las respuestas degradaría.

6.3. El re-ranker

El re-ranker es un *cross-encoder*: a diferencia del encoder de embeddings (que procesa query y chunk por separado), el cross-encoder analiza el par (query, chunk) de forma conjunta. Esto permite capturar interacciones semánticas más sutiles y produce una ordenación más precisa. El costo es mayor latencia, justificada aquí porque el corpus es pequeño y los tiempos son aceptables.

6.4. Modelo generador: Mistral-7B-Instruct-v0.3

Se eligió Mistral-7B por tres razones: (1) es de código abierto y no tiene costo de API; (2) su variante *Instruct* sigue instrucciones de forma fiable, incluyendo la restricción de citar fuentes; (3) con cuantización 4-bit NF4 (`BitsAndBytesConfig`) cabe en la GPU T4 de Colab (≈ 5 GB de VRAM frente a los ≈ 16 GB del modelo en precisión completa).

7. Resultados

7.1. Preguntas de evaluación

Se formularon 5 preguntas representativas que un analista de cine académico le haría al sistema.

7.1.1. Pregunta 1: Alienación masculina

“¿Cómo representan estas películas la alienación masculina?”

El sistema recuperó chunks de Bronfen (a5), Montero (a6), Petković (a4) y los ensayos de Ebert sobre Taxi Driver y Raging Bull. La respuesta identificó correctamente el

aislamiento social de Travis Bickle, la disociación identitaria del Narrador en *Fight Club* y la incomunicación de LaMotta como manifestaciones paralelas de alienación masculina posmoderna. Cinco fuentes citadas. Sin alucinaciones.

7.1.2. *Pregunta 2: Violencia e identidad*

“¿Qué relación existe entre violencia e identidad en el cine contemporáneo?”

El sistema articuló la violencia como mecanismo de afirmación identitaria en contextos de crisis de masculinidad, apoyándose en Bronfen y Vidyalakshmi. La respuesta conectó correctamente la pérdida de rol social con la búsqueda de reconocimiento a través de la violencia física. Cinco fuentes citadas. Sin alucinaciones.

7.1.3. *Pregunta 3: Justificación moral de la violencia*

“¿Cómo justifican moralmente la violencia los protagonistas de Taxi Driver y Fight Club?”

El sistema diferenció con precisión las dos lógicas: Travis Bickle como figura mesiánica que racionaliza la violencia como purificación moral urbana, y el Narrador de *Fight Club* como rechazo al vacío del consumismo. Los chunks de Petković y Montero fueron los más relevantes. Cinco fuentes citadas. Sin alucinaciones.

7.1.4. *Pregunta 4: Diferencias entre Taxi Driver y No Country for Old Men*

“¿Qué diferencias existen entre la representación de la violencia en Taxi Driver y No Country for Old Men?”

El sistema identificó correctamente la oposición entre violencia redentora (*Taxi Driver*) y violencia nihilista sin consecuencias morales (*No Country*). Sin embargo, en esta respuesta se detectó una **alucinación**: el modelo hizo referencia a una película externa al corpus definido, incorporando conocimiento paramétrico de Mistral-7B sobre el cine de violencia en general. El sistema no detectó esta desviación automáticamente. Se analiza en la Sección 7.3.

7.1.5. *Pregunta 5: Nihilismo*

“¿Qué papel juega el nihilismo en la construcción de los protagonistas de estas películas?”

El sistema recuperó fragmentos de Almeida (a8), Potts (a2) y Arif (a1), articulando el nihilismo como respuesta a la ausencia de valores y el absurdo existencial. La respuesta fue completa y trazable. Cinco fuentes citadas. Sin alucinaciones.

7.2. Tabla resumen de calidad

Cuadro 7: Análisis cualitativo de las 5 preguntas de evaluación.

#	Tema	Correcta	Completa	Citó fuentes	¿Alucinó?
1	Alienación masculina	Sí	Sí	5	No
2	Violencia e identidad	Sí	Sí	5	No
3	Justificación moral	Sí	Sí	5	No
4	Taxi Driver vs. No Country	Sí	Sí	5	Sí
5	Nihilismo	Sí	Sí	5	No

7.3. Caso de fallo y análisis

Pregunta: “¿Cuál es la opinión personal del director de *Raging Bull* sobre la masculinidad?”

Esta pregunta está diseñada para evidenciar los límites del sistema: solicita información biográfica subjetiva de Martin Scorsese que no aparece en ninguno de los 12 documentos del corpus. El sistema recuperó chunks sobre masculinidad en *Raging Bull* en general (material tangencialmente relacionado), y la instrucción de “responder solo con el contexto” logró que el modelo indicara parcialmente que la información no estaba disponible. Sin embargo, la respuesta no fue completamente vacía: el LLM incorporó conocimiento paramétrico sobre Scorsese, lo que constituye una alucinación.

¿Por qué ocurrió? Mistral-7B tiene conocimiento previo sobre directores de cine en sus datos de entrenamiento. La instrucción en el prompt reduce pero no elimina este conocimiento paramétrico. El sistema carece de un mecanismo que verifique que cada afirmación de la respuesta sea trazable a un chunk recuperado.

Trazabilidad: En las 4 preguntas sin alucinación, el sistema citó correctamente 5 fuentes con formato [n], lo que permite al usuario verificar directamente en qué documento y fragmento se basa cada afirmación.

8. Limitaciones y Conclusiones

8.1. Limitaciones identificadas

1. **Tamaño del corpus.** Con 12 documentos, la cobertura temática es sólida pero limitada en profundidad. Preguntas muy específicas sobre escenas particulares o personajes secundarios pueden no tener suficiente representación en el corpus.
2. **Control imperfecto de alucinaciones.** La restricción “responde EXCLUSIVAMENTE con el contexto” reduce las alucinaciones pero no las elimina. Un sistema de producción requeriría un verificador adicional que compruebe que cada afirmación sea trazable a un chunk recuperado.

3. **Velocidad de inferencia.** La cuantización 4-bit permite ejecutar Mistral-7B en la GPU T4 de Colab, pero cada respuesta tarda entre 20 y 60 segundos. Esto hace inviable el sistema para uso interactivo con múltiples usuarios simultáneos.
4. **Conversión aproximada de scores.** FAISS con índice Flat devuelve distancia L2, no similitud coseno directa. La fórmula $\text{sim} \approx 1/(1 + d_{L2})$ es una aproximación funcional; el umbral de 0.6 es una heurística, no un valor calibrado sobre el corpus.
5. **Sin memoria conversacional.** Cada consulta es independiente. El sistema no puede manejar preguntas de seguimiento del tipo “¿y en Raging Bull?” después de una respuesta previa.

8.2. Propuestas de mejora

- **Retriever híbrido BM25 + embeddings.** Combinar búsqueda lexical con búsqueda semántica mejoraría la cobertura en términos técnicos específicos (nombres de directores, títulos exactos) donde el embedding semántico es menos preciso.
- **Threshold de confianza.** Rechazar automáticamente consultas donde ningún chunk supere un score mínimo, respondiendo “Esta pregunta está fuera del alcance del corpus”.
- **Expansión del corpus.** Incorporar subtítulos de las películas o transcripciones de entrevistas permitiría cubrir preguntas sobre declaraciones de directores y actores.
- **Evaluación automática con RAGAS.** Implementar métricas de *faithfulness* y *answer relevancy* sobre las 5 preguntas para obtener scores cuantitativos complementarios al análisis cualitativo.

8.3. Conclusiones

El sistema RAG construido demuestra que es posible crear una herramienta de análisis cinematográfico académico que supere las limitaciones de un LLM genérico. Las respuestas están fundamentadas en el corpus, citan sus fuentes con trazabilidad, y en 4 de las 5 preguntas evaluadas no presentaron alucinaciones detectables. El pipeline — chunking → embeddings → FAISS → re-ranking → Mistral-7B — es reproducible, modular y escalable a corpus más grandes con mínimas modificaciones.

El caso de alucinación detectado en la Pregunta 4 es uno de los hallazgos más valiosos del proyecto: confirma que la evaluación cualitativa es indispensable en sistemas RAG, y que la trazabilidad de fuentes es el mecanismo más confiable para detectar cuándo el modelo se aparta del corpus. Desde una perspectiva de diseño, este hallazgo refuerza la importancia de instrucciones de sistema precisas y de mecanismos de verificación post-generación.

8. Bibliografía

8.3. Corpus documental

- [1] Arif, S. N. *The Fragile World of Cormac McCarthy's No Country for Old Men*. Paper académico.
- [2] Potts, H. *No Country for Old Men as Existential Confession*. Paper académico.
- [3] Vidyalakshmi, A. C. *Quest for Identity, Desire and Dreams: The Resistance to the Consumerist Ideology in Fight Club, a Psychoanalytic Study*. Paper académico.
- [4] Petković, R. y Jurleta, G. *Martin Scorsese's Character Driven Films: The Study of Main Protagonists in Taxi Driver (1976) and Raging Bull (1980)*. Paper académico.
- [5] Bronfen, E. *Noir Hysteria: Figures of Masculinity in Crisis in Contemporary Hollywood Cinema*. Paper académico.
- [6] Montero Gimeno, N. *"You Are Not the Contents of Your Wallet": Narrative Structure, Alienation and Capitalism in Fight Club (1999)*. Paper académico.
- [7] García López, J. *The Alienated City in 21st Century Cinema: A Socio-Critical Analysis*. Paper académico.
- [8] Almeida, R. de. *Impotence, Resentment, Incredulity: Nihilism in Cinema and Education*. Paper académico.
- [9] Ebert, R. *Taxi Driver* (ensayo crítico). <https://www.rogerebert.com>
- [10] Ebert, R. *Fight Club* (ensayo crítico). <https://www.rogerebert.com>
- [11] Ebert, R. *Raging Bull* (ensayo crítico). <https://www.rogerebert.com>
- [12] Ebert, R. *No Country for Old Men* (ensayo crítico). <https://www.rogerebert.com>